ESTUDIO DE TÉCNICAS DE SLAM MONOCULAR EN TIEMPO REAL PER A ENTORNOS EXTERIORES

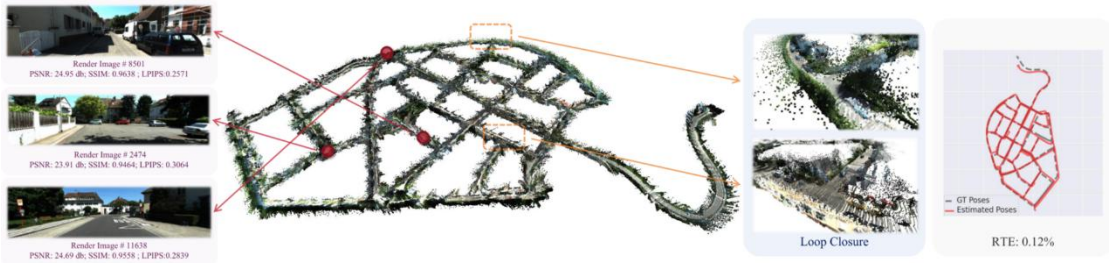

INFORME INICIAL

Yanhao Lin

1670136

Mención de Computación

Treball Final del Grau

Tutor: Felipe Lumbreras Ruiz

Contenido

1. Introducción 2
2. Motivación 3
3. Objetivos del TFG 4
4. Metodología 5
5. Planificación y Pasos a seguir 7
6. Estado del Arte 10
   6.1. Fundamentos Geométricos y Reconstrucción Basada en SfM 10
   6.2. Aprendizaje Profundo: MASt3R-SLAM 10
   6.3. Representación Volumétrica: 3D Gaussian Splatting 11
7. Uso de IA generativa 12
8. Bibliografía 13

1. Introducción

El problema del SLAM (Simultaneous Localization and Mapping) consiste en estimar simultáneamente la trayectoria de una cámara y reconstruir el entorno en el que se encuentra. En particular, el SLAM monocular permite a un dispositivo construir un mapa 3D de un entorno desconocido y calcular su propia posición y orientación en tiempo real utilizando una única cámara convencional.

El estudio de SLAM monocular en entornos exteriores es especialmente relevante para aplicaciones como drones, robótica al aire libre y sistemas de realidad aumentada, donde las condiciones de iluminación, textura y dinámica de la escena son variables.

En los últimos años, técnicas basadas en Structure from Motion (SfM) como COLMAP han demostrado gran eficacia en la reconstrucción 3D a partir de imágenes. Más recientemente, métodos de representación neuronal como Gaussian Splatting han permitido generar reconstrucciones densas y visualmente realistas en tiempo real.

Este trabajo se centra en el estudio, implementación y evaluación de técnicas de SLAM monocular en tiempo real para entornos exteriores, integrando reconstrucción 3D mediante COLMAP, exploración de MASt3R-SLAM y representación avanzada mediante Gaussian Splatting.

2. Motivación

El desarrollo de técnicas de SLAM monocular en tiempo real es un área de gran relevancia en visión por computador y robótica, especialmente en entornos exteriores donde las condiciones de iluminación, textura y movimiento pueden ser variables y desafiantes.

El estudio de estas técnicas busca mejorar la precisión de estimación de trayectoria, la robustez frente a cambios ambientales y la calidad de la reconstrucción 3D. Además, la integración de enfoques clásicos, aprendizaje profundo y representaciones avanzadas como Gaussian Splatting permite generar pipelines completos y eficientes para aplicaciones prácticas.

La motivación del proyecto radica en la necesidad de sistemas SLAM que sean capaces de funcionar en tiempo real, con alta fidelidad visual y bajo consumo computacional, abriendo posibilidades para aplicaciones en drones, vehículos autónomos, robótica al aire libre y sistemas de realidad aumentada.

Este trabajo también tiene como objetivo proporcionar un análisis comparativo entre técnicas clásicas y modernas, identificando ventajas, limitaciones y oportunidades de mejora en la implementación de SLAM monocular en entornos exteriores.

3. Objetivos del TFG

El objetivo general y principal del trabajo es estudiar, implementar y evaluar experimentalmente un pipeline de SLAM monocular en tiempo real para entornos exteriores, generando reconstrucciones 3D del entorno y explorando técnicas avanzadas de representación.

Analizando de manera más específica, se trata de:

- **Estudiar el estado del arte en SLAM monocular**, identificando ventajas, limitaciones y desafíos específicos en entornos exteriores.
- **Diseñar e implementar un pipeline de reconstrucción 3D monocular**:
  - Captura de imágenes o vídeo.
  - Extracción de frames.
  - Reconstrucción 3D con COLMAP.
  - Generación de nube de puntos y modelos densos del entorno.
- **Implementar y evaluar MASt3R-SLAM** como alternativa basada en Deep Learning para estimación de trayectoria y reconstrucción en entornos exteriores, analizando su robustez frente a variaciones de iluminación y textura.
- **Aplicar técnicas de Gaussian Splatting** sobre las reconstrucciones obtenidas, evaluando mejoras en representación visual y eficiencia de renderizado.
- **Evaluar y aplicar métricas para comparar los diferentes enfoques**:
  - Precisión de trayectoria.
  - Robustez ante condiciones variables en exteriores.
  - Coherencia de la nube de puntos.
  - Tiempo de procesamiento.
  - Consumo computacional.
  - Calidad visual de reconstrucción.

Impacto esperado

Se espera determinar qué técnicas ofrecen el mejor equilibrio entre precisión, eficiencia y calidad visual en entornos exteriores, proporcionando una guía para futuras implementaciones de SLAM monocular.

4. Metodología

La metodología será principalmente experimental y comparativa, combinando:

Revisión bibliográfica

- Técnicas clásicas de SLAM monocular basadas en SfM.
- Herramientas como COLMAP.
- Herramientas de aprendizaje profundo como MASt3R-SLAM.
- Técnicas modernas de representación 3D como Gaussian Splatting.

Diseño e implementación de pipelines

- **Pipeline clásico basado en SfM (COLMAP)**
    1. Captura de vídeo en entornos exteriores.
    2. Extracción de frames relevantes.
    3. Estimación de correspondencias entre imágenes.
    4. Reconstrucción inicial mediante Structure from Motion.
    5. Generación de nube de puntos densa.
    6. Exportación del modelo 3D.
- **Pipeline basado en priors aprendidos (MASt3R-SLAM)**
    1. Predicción 3D entre pares de imágenes mediante la red MASt3R.
    2. Estimación de trayectoria y reconstrucción densa.
    3. Evaluación en escenarios exteriores.
    4. Análisis de robustez ante variaciones de iluminación y textura.
- **Integración con Gaussian Splatting**
    1. Conversión de nubes de puntos en formatos compatibles.
    2. Aplicación de Gaussian Splatting para generar representaciones 3D continuas y visualmente realistas.
    3. Evaluación de calidad de renderizado y coherencia geométrica.

Evaluación experimental

- **Cuantitativa:** Precisión de trayectoria (ATE, RPE), densidad de nube de puntos, tiempo de procesamiento, consumo computacional, estabilidad ante variaciones de iluminación.

- **Cualitativa:** Calidad visual de reconstrucción, presencia de artefactos, coherencia global del mapa, robustez en escenas con baja textura o elementos dinámicos.

Herramientas y Entorno de Desarrollo

El desarrollo se realizará principalmente en:

- Python como lenguaje principal.
- Librerías de visión por computador.
- Frameworks proporcionados por MASt3R-SLAM.

Estrategia de seguimiento y control de versiones

En el marco de este proyecto, se ha adoptado una metodología de desarrollo basada en las buenas prácticas de la ingeniería de software. Para garantizar un control riguroso sobre la evolución del software y facilitar la reproducibilidad de los experimentos, todo el contenido generado durante el trabajo se ha alojado en un **repositorio de GitHub**.

El uso de este sistema de control de versiones distribuido (basado en Git) ofrece una buena gestión del desarrollo y un buen control de automatización y flujos de trabajo.

El código fuente, los scripts de automatización y la documentación completa se encuentran disponibles de forma pública en el siguiente repositorio: https://github.com/jimlin829/tfg-slam-monocular

El progreso del proyecto también se evaluará periódicamente mediante **reuniones con el tutor** y **validación de resultados parciales**.

5. Planificación y Pasos a seguir

El desarrollo del trabajo se organizará en fases secuenciales, siguiendo una planificación estructurada que permita avanzar de forma progresiva desde el estudio teórico hasta la validación experimental y redacción final.

Se adoptará un enfoque incremental, validando cada bloque del proyecto antes de avanzar al siguiente, con el objetivo de reducir riesgos técnicos y garantizar la coherencia global del trabajo.

Asimismo, la redacción de la memoria se realizará de forma paralela al desarrollo técnico, evitando concentrar la documentación únicamente en la fase final.

El proyecto se dividirá en las siguientes grandes fases:

Fase 1 – Estudio y definición del marco teórico

Objetivo: establecer una base conceptual sólida.

Durante esta fase se realizará:

- Revisión bibliográfica sobre SLAM monocular.
- Estudio de técnicas clásicas basadas en Structure from Motion (COLMAP).
- Análisis de enfoques recientes basados en aprendizaje profundo (MASt3R-SLAM).
- Estudio de técnicas de representación 3D como Gaussian Splatting.
- Definición del alcance definitivo del proyecto.
- Delimitación clara de objetivos específicos.

Fase 2 – Preparación del entorno y herramientas

Objetivo: preparar el entorno técnico necesario para el desarrollo experimental.

Tareas:

- Configuración del entorno de desarrollo (Python, dependencias, entorno GPU si procede).
- Instalación y validación de COLMAP.

- Instalación y prueba inicial de MASt3R-SLAM.
- Organización del sistema de almacenamiento de datos.
- Definición del protocolo de captura de vídeo en exteriores.

Fase 3 – Desarrollo del pipeline clásico

Objetivo: implementar y validar el pipeline basado en técnicas tradicionales.

Tareas:

- Captura de secuencias de vídeo en exteriores.
- Extracción de frames.
- Reconstrucción mediante COLMAP.
- Generación de nube de puntos.
- Análisis preliminar de resultados.

Fase 4 – Implementación y evaluación del enfoque basado en aprendizaje profundo

Objetivo: analizar la viabilidad del uso de MASt3R-SLAM en el contexto del proyecto.

Tareas:

- Ejecución de MASt3R-SLAM sobre las mismas secuencias.
- Evaluación de la trayectoria estimada.
- Generación de reconstrucciones densas.
- Medición de tiempos de procesamiento.
- Identificación de fortalezas y limitaciones.

Fase 5 – Integración con Gaussian Splatting

Objetivo: analizar el impacto del método de reconstrucción inicial en la representación final.

Tareas:

- Conversión de las reconstrucciones obtenidas.

- Aplicación de Gaussian Splatting.
- Evaluación visual y técnica del resultado.
- Comparación entre reconstrucciones generadas a partir de distintos pipelines.

Fase 6 – Análisis global y conclusiones

Objetivo: realizar una evaluación crítica del trabajo realizado.

Tareas:

- Comparación cuantitativa y cualitativa de resultados.
- Discusión sobre robustez, precisión y eficiencia.
- Identificación de limitaciones.
- Propuesta de posibles líneas futuras.

Fase 7 – Redacción final y preparación de la defensa

Objetivo: consolidar y presentar el trabajo realizado.

Tareas:

- Redacción completa de la memoria.
- Revisión técnica y formal.
- Elaboración de figuras y gráficos.
- Preparación de la presentación oral.

Diagrama de Gantt de la planificación

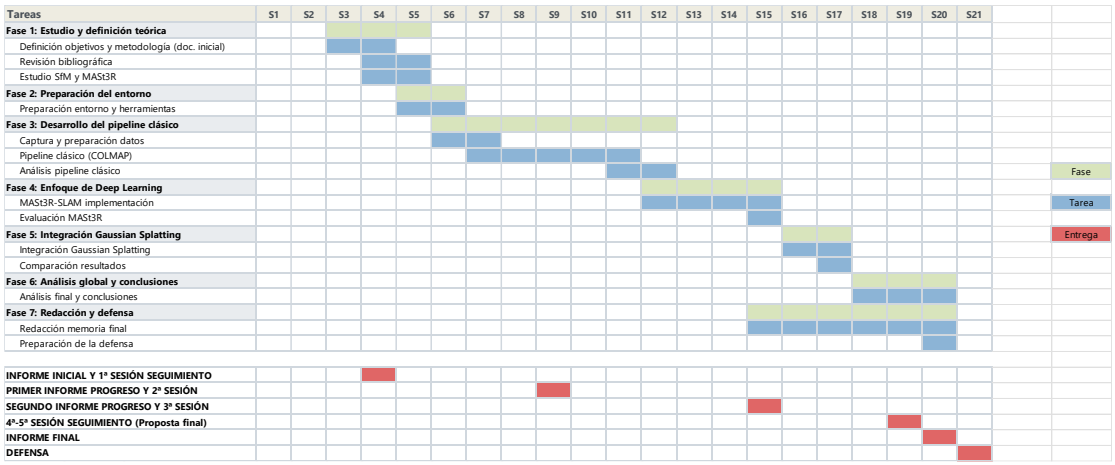

6. Estado del Arte

El desarrollo del SLAM monocular ha evolucionado desde enfoques puramente geométricos apoyados en librerías clásicas, hacia sistemas híbridos que integran aprendizaje profundo y nuevas formas de representación volumétrica.

6.1. Fundamentos Geométricos y Reconstrucción Basada en SfM

Los métodos clásicos de reconstrucción 3D y localización visual se basan en la geometría proyectiva y multivista. Básicamente, Structure from Motion (SfM) busca estimar al mismo tiempo la forma tridimensional de una escena y la posición de las cámaras a partir de varias imágenes [2].

Con SfM se puede obtener un mapa inicial del entorno, que luego se puede densificar usando Multi-View Stereo (MVS) para conseguir nubes de puntos más completas y modelos más detallados [3]. Paralelamente, SLAM se centra en estimar la trayectoria de la cámara mientras se construye un mapa del entorno. En el caso del SLAM monocular, no tener información directa de profundidad hace que haya ambigüedad de escala y más complejidad. Sistemas como ORB-SLAM han mostrado que es posible lograr estimaciones bastante precisas en tiempo real gracias a la detección y emparejamiento de características visuales [1].

Dentro de este enfoque geométrico, COLMAP es una de las herramientas más usadas. Su pipeline incluye:

- Detección y emparejamiento de características.
- Estimación incremental de la posición de la cámara.
- Optimización global con bundle adjustment.
- Reconstrucción densa con MVS [4].

COLMAP es bastante robusto y preciso, aunque su enfoque principal está pensado para procesamiento offline, lo que puede limitarlo en escenarios que necesitan tiempo real.

6.2. Aprendizaje Profundo: MASt3R-SLAM

El aprendizaje profundo ha abierto nuevas formas de abordar SLAM. A diferencia de los métodos clásicos, estos enfoques aprenden directamente a partir de los datos cómo representar la escena en 3D.

Un ejemplo es **DUSt3R**, que predice mapas 3D consistentes entre dos vistas [5]. A partir de esto se desarrolló **MASt3R**, que mejora el emparejamiento y la coherencia geométrica.

MASt3R-SLAM construye un SLAM monocular denso en tiempo real usando estas predicciones aprendidas [6]. En vez de depender solo de características locales, la red neuronal genera predicciones 3D densas que permiten:

- Emparejar imágenes.
- Estimar la trayectoria.
- Fusionar el mapa de manera incremental.
- Optimizar globalmente.

Este método es más robusto en escenas complejas, aunque necesita más potencia computacional y hardware adecuado.

6.3. Representación Volumétrica: 3D Gaussian Splatting

Más allá de las nubes de puntos clásicas, han aparecido técnicas de representación 3D que buscan mejorar la calidad visual y la eficiencia al renderizar. Un ejemplo es **3D Gaussian Splatting**, que representa la escena con un conjunto de gaussianas 3D optimizadas para renderizado en tiempo real [7].

Este enfoque permite:

- Representaciones densas y continuas.
- Alta calidad visual.
- Renderizado rápido.

Combinar esta técnica con reconstrucciones geométricas permite obtener modelos más realistas y completos del entorno [8].

7. Uso de IA generativa

Durante el desarrollo de este Trabajo Final de Grado, se ha hecho uso de herramientas de inteligencia artificial generativa de manera ética y transparente, siguiendo las normativas de integridad académica.

Específicamente, se han utilizado modelos como Gemini y NotebookLM para tareas de apoyo que no afectan directamente a los resultados experimentales:

- **Revisión y mejora de redacción:** Corrección de estilo, ortografía y coherencia estructural de los apartados de la memoria.
- **Soporte bibliográfico:** Síntesis y traducción de artículos científicos relevantes en inglés, relacionados con SLAM, MVS, MASt3R y 3D Gaussian Splatting.
- **Asistencia en programación:** Orientación puntual en la depuración de errores y en la configuración de entornos de ejecución para COLMAP y modelos de aprendizaje profundo.

No se ha utilizado IA generativa para:

- Generar resultados experimentales sin validación propia.
- Crear código crítico cuya exactitud no haya sido comprobada.

Esta aproximación asegura que la IA actúe únicamente como herramienta de apoyo, manteniendo la autoría y responsabilidad del trabajo, y garantizando la integridad de los resultados obtenidos.

8. Bibliografía

[1] R. Mur-Artal, J. M. M. Montiel and J. D. Tardós, "ORB-SLAM: A Versatile and Accurate Monocular SLAM System," IEEE Transactions on Robotics, vol. 31, no. 5, pp. 1147–1163, 2015.

[2] J. L. Schönberger and J.-M. Frahm, "Structure-from-Motion Revisited," Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2016.

[3] J. L. Schönberger, E. Zheng, J.-M. Frahm and M. Pollefeys, "Pixelwise View Selection for Unstructured Multi-View Stereo," European Conference on Computer Vision (ECCV), 2016.

[4] COLMAP – Structure-from-Motion and Multi-View Stereo Software. Available: https://colmap.github.io/

[5] DUSt3R GitHub Repository. Available: https://github.com/naver/dust3r

[6] MASt3R-SLAM GitHub Repository. Available: https://github.com/rmurai0610/MASt3R-SLAM

[7] B. Kerbl, G. Kopanas, T. Leimkühler and G. Drettakis, "3D Gaussian Splatting for Real-Time Radiance Field Rendering," ACM Transactions on Graphics (SIGGRAPH), 2023.

[8] 3D Gaussian Splatting Project – INRAE. Available: https://github.com/graphdeco-inria/gaussian-splatting